

# 统计学习方法

## 第四章 朴素贝叶斯法 (Naive Bayes)

黄嘉锋

2018. 10. 26

# 第四章 朴素贝叶斯法

4.1 朴素贝叶斯法的学习与分类

4.2 朴素贝叶斯法的参数估计

4.3 总结

## 4.1.1 基本方法

- 定义：
  - 输入空间： $\mathcal{X} \subseteq R^n$ ，输出空间： $\mathcal{Y} = \{c_1, c_2, \dots, c_k\}$
  - 输入输出：特征向量 $x \in \mathcal{X}$ ，类标记 $y \in \mathcal{Y}$
  - $X$ 是定义在 $\mathcal{X}$ 上的随机向量
  - $Y$ 是定义在 $\mathcal{Y}$ 上的随机向量
  - 训练数据集： $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$

## 4.1.1 基本方法

- 概率定义：

- 先验概率： $P(Y = c_k), k = 1, 2, \dots, K$

- 条件概率：

$$P(X = x|Y = c_k) = P(X^{(1)} = x^{(1)}, \dots, X^{(n)} = x^{(n)}|Y = c_k),$$
$$k = 1, 2, \dots, K$$

- 联合概率： $P(X, Y)$

## 4.1.1 基本方法

- 条件概率分布 $P(X = x|Y = c_k)$ 有指数数量的参数：
  - 假设 $x^{(j)}$ 可取值有 $S_j$ 个,  $j = 1, 2, \dots, n$ ,  $Y$ 可取值有 $K$ 个, 那么参数个数为

$$K \prod_{j=1}^n S_j$$

## 4.1.1 基本方法

- 条件独立性假设→

$$\begin{aligned} P(X = x | Y = c_k) &= P(X^{(1)} = x^{(1)}, \dots, X^{(n)} = x^{(n)} | Y = c_k) \\ &= \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_k) \end{aligned}$$

## 4.1.1 基本方法

- 将后验概率 $P(Y = c_k | X = x)$ 最大的类作为 $x$ 的类输出:

$$P(Y = c_k | X = x) = \frac{P(X = x | Y = c_k)P(Y = c_k)}{\sum_k P(X = x | Y = c_k)P(Y = c_k)}$$

$$= \frac{P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c_k)}{\sum_k P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c_k)}, \quad k = 1, 2, \dots, K$$

- 其中分母对所有 $c_k$ 都是相同的

## 4.1.1 基本方法

- 朴素贝叶斯分类器简化为：

$$y = \arg \max_{c_k} P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c_k)$$



## 4. 1. 2 后验概率最大化的含义

- 0-1损失函数: 
$$L(Y, f(X)) = \begin{cases} 1, Y \neq f(X) \\ 0, Y = f(X) \end{cases}$$

- 期望风险函数: 
$$R_{exp}(f) = E[L(Y, f(X))]$$

- 条件期望: 
$$R_{exp}(f) = E_x \sum_{k=1}^K [L(c_k, f(X))] P(c_k | X)$$

## 4.1.2 后验概率最大化的含义

- 使期望风险最小化，对 $X = x$ 逐个极小化：

$$f(x) = \arg \min_{y \in \mathcal{Y}} \sum_{k=1}^K L(c_k, y) P(c_k | X = x)$$

$$= \arg \min_{y \in \mathcal{Y}} \sum_{k=1}^K P(y \neq c_k | X = x)$$

$$= \arg \min_{y \in \mathcal{Y}} (1 - P(y = c_k | X = x))$$

$$= \arg \max_{y \in \mathcal{Y}} P(y = c_k | X = x)$$

# 第四章 朴素贝叶斯法

4.1 朴素贝叶斯法的学习与分类

4.2 朴素贝叶斯法的参数估计

4.3 总结

## 4.2.1 极大似然估计

- 先验概率 $P(Y = c_k)$ :

$$P(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k)}{N}, k = 1, 2, \dots, K$$

- 设 $x^{(j)}$ 可能取值为 $\{a_{j1}, a_{j2}, \dots, a_{jS_j}\}$ , 条件概率 $P(X^{(j)} = a_{jl} | Y = c_k)$ :

$$P(X^{(j)} = a_{jl} | Y = c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{jl}, y_i = c_k)}{\sum_{i=1}^N I(y_i = c_k)},$$

$$j = 1, 2, \dots, n; l = 1, 2, \dots, S_j; k = 1, 2, \dots, K$$

## 4.2.2 学习与分类算法

- 计算先验概率及条件概率：

$$P(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k)}{N}, k = 1, 2, \dots, K$$

$$P(X^{(j)} = a_{jl} | Y = c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{jl}, y_i = c_k)}{\sum_{i=1}^N I(y_i = c_k)},$$

$$j = 1, 2, \dots, n; l = 1, 2, \dots, S_j; k = 1, 2, \dots, K$$

## 4.2.2 学习与分类算法

- 对于给定的实例  $x = (x^{(1)}, x^{(2)}, \dots, x^{(n)})^T$ , 计算:

$$P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c_k), \quad k = 1, 2, \dots, K$$

- 确定  $x$  的类:

$$y = \arg \max_{c_k} P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c_k)$$

## 4.2.3 贝叶斯估计

- 先验概率：

$$P_{\lambda}(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k) + \lambda}{N + K\lambda}, k = 1, 2, \dots, K$$

- 条件概率：

$$P_{\lambda}(X^{(j)} = a_{jl} | Y = c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{jl}, y_i = c_k) + \lambda}{\sum_{i=1}^N I(y_i = c_k) + S_j\lambda}$$

- $\lambda \geq 0$ ,  $\lambda = 0$ 为极大似然估计,  $\lambda = 1$ 为拉普拉斯平滑 (Laplace smoothing)

# 第四章 朴素贝叶斯法

4.1 朴素贝叶斯法的学习与分类

4.2 朴素贝叶斯法的参数估计

4.3 总结



## 4.3 总结

- 朴素贝叶斯法的生成方法
- 朴素贝叶斯法的基本假设
- 期望角度的朴素贝叶斯法